# Diferenciálna evolúcia
# Differential Evolution

## Obsah

**Úloha 5: Diferenciálna evolúcia** **2**
Cieľ úlohy . . . 2
Definícia úlohy . . . 2
Postup riešenia . . . 2

**Odovzdanie a hodnotenie** **3**
Dokumentácia výsledkov (PDF) . . . 3
Obhajoba riešenia . . . 3

**Odporúčané nástroje a technická realizácia** **4**
MATLAB . . . 4
Python . . . 4

**Teoretické poznámky** **5**
Parametre, hranice a interpretácia výsledkov . . . 5

# Úloha 5: Diferenciálna evolúcia (4 b)

## Cieľ úlohy

Navrhnite a naprogramujte algoritmus diferenciálnej evolúcie (DE) na minimalizáciu Schwefelovej funkcie desiatich premenných. Preskúmajte vplyv parametrov algoritmu a výsledky porovnajte s genetickým algoritmom zo zadania 1.

## Definícia úlohy

Pre výpočet fitness použite funkciu `testfn3`. Veľkosť populácie nastavte na **50 jedincov**. Pre DE aj GA použite rovnaký rozsah premenných, počet generácií, ukončovaciu podmienku a rovnakú sadu piatich seedov.

## Postup riešenia

1. Implementujte základný variant *DE/rand/1/bin* s diferenciálnou mutáciou, binomickým krížením a výberom lepšieho jedinca.
2. Experimentálne porovnajte viacero dvojíc parametrov $F$ a $CR$. Ostatné nastavenia počas porovnania nemeňte. Vyberte jednu dvojicu parametrov a svoj výber stručne zdôvodnite.
3. Vybrané nastavenie DE spustite päťkrát. V každej generácii zaznamenajte najlepšiu dovtedy dosiahnutú hodnotu fitness.
4. S rovnakými seedmi vykonajte päť behov GA zo zadania 1. GA musí používať populáciu rovnakej veľkosti a rovnaké spoločné podmienky ako DE.
5. Vytvorte graf piatich behov DE a ich priemerného priebehu. V druhom grafe zobrazte päť behov DE, ich priemer, päť behov GA a ich priemer.
6. Výsledky spracujte aj do tabuliek. Uveďte skúšané hodnoty $F$ a $CR$, výslednú fitness jednotlivých behov, priemer, smerodajnú odchýlku a najlepší nájdený vektor. Stručne porovnajte konvergenciu a kvalitu riešení oboch algoritmov.

---

Poznámka: **Minimálne sa očakávajú dva grafy: graf piatich behov DE s ich priemerom a spoločný porovnávací graf piatich behov DE, piatich behov GA a priemerov oboch algoritmov.** V grafoch zobrazujte najlepšiu dovtedy dosiahnutú fitness. Jednotlivé behy vykreslite jemnejšími čiarami a priemer zvýraznite. Oba algoritmy porovnávajte pri rovnakej mierke osí. Grafy musia obsahovať názov, popisy osí a legendu. Screenshoty sa nepovažujú za spracovanie výsledkov.

# Odovzdanie a hodnotenie

Hodnotenie zadania prebieha formou osobnej konzultácie. Zadanie sa odovzdáva vždy na **začiatku cvičenia** po odprezentovaní nasledujúceho zadania.

Počas semestra môže študent nahradiť najviac dve cvičenia. V takom prípade je možné zadanie odovzdať aj na cvičení, na ktorom študent nahrádza. V ostatných prípadoch sa zadanie odovzdáva vždy svojmu cvičiacemu.

Toto zadanie je hodnotené najviac 4 bodmi a neobsahuje bonusovú časť.

## Dokumentácia výsledkov (PDF)

Pripravte stručnú správu vo formáte PDF, ktorá obsahuje požadované grafy a tabuľky z viacerých nezávislých spustení, použité nastavenia algoritmu a krátku analýzu výsledkov. Dokument musí byť pripravený pred začiatkom obhajoby, aby nebolo nutné čakať na opakované výpočty počas konzultácie.

Grafy exportujte priamo z použitého prostredia v dostatočnej kvalite, nie formou screenshotov. Každý graf musí obsahovať názov, popisy osí, čitateľnú mierku a legendu, ak zobrazuje viac priebehov. Výsledky spracujte do prehľadných tabuliek. samotný neupravený výpis z konzoly sa nepovažuje za dokumentáciu.

Pre toto zadanie uveďte v správe tabuľku skúšaných parametrov, graf piatich behov DE s priemerom, spoločný graf behov DE a GA s ich priemermi a tabuľku finálnych výsledkov. Pri najlepšom výsledku uveďte aj nájdený vektor desiatich premenných.

## Obhajoba riešenia

Súčasťou hodnotenia je demonštrácia funkčného kódu a vysvetlenie implementácie. Body sa udeľujú najmä za porozumenie princípu algoritmu, použitým operátorom a schopnosť zdôvodniť zvolené parametre a dosiahnuté výsledky, nie iba za spustiteľný program.

Pri obhajobe buďte pripravení vysvetliť, ako sa v implementácii prejavuje selektívny tlak, diverzita populácie, kríženie a jednotlivé typy mutácie, a interpretovať rozdiely medzi opakovanými behmi.

Pri obhajobe vysvetlite diferenciálnu mutáciu, význam parametrov $F$ a $CR$, binomické kríženie, výber skúšobného jedinca a spôsob zabezpečenia porovnateľných podmienok pre DE a GA.

## Odporúčané nástroje a technická realizácia

Zadanie je možné vypracovať v prostredí **MATLAB** alebo v jazyku **Python**. V oboch prostrediach zachovajte rovnakú experimentálnu metodiku a rovnaký rozsah dokumentácie.

### MATLAB

Pri riešení v MATLABe použite testovaciu funkciu `testfn3.m` a podklady dostupné v AIS. Diferenciálnu evolúciu implementujte vo vlastnom programe. Program `GA01` a príslušnú verziu Genetic Toolboxu použite na vytvorenie porovnávacích behov GA.

### Python

Pri riešení v Pythone je odporúčané prostredie Google Colab (`https://colab.research.google.com/`) alebo lokálny Jupyter Notebook.

Pre výpočet fitness použite `kod/testfn3.py` z repozitára UI2-GA. Na numerické operácie môžete použiť `NumPy` a na vytvorenie grafov `Matplotlib`. Riadiaci cyklus DE spracujte vo vlastnom programe. GA zo zadania 1 použite iba na vytvorenie porovnávacích behov.

# Teoretické poznámky

Diferenciálna evolúcia je populačný optimalizačný algoritmus určený najmä pre spojité číselné premenné. Riešenie je reprezentované vektorom $\boldsymbol{x}_i^t = (x_{i,1}^t, x_{i,2}^t, \ldots, x_{i,n}^t)$, kde $i$ označuje jedinca a $t$ generáciu. Populácia obsahuje viacero kandidátnych riešení, ktoré sa postupne menia pomocou rozdielov medzi jej vlastnými jedincami. Veľkosť a smer zmeny preto prirodzene závisia od aktuálneho rozloženia populácie v priestore riešení.

Pri variante *DE/rand/1/bin* sa pre každého cieľového jedinca $\boldsymbol{x}_i^t$ vyberú tri navzájom rôzne indexy $r_1$, $r_2$ a $r_3$. Tieto indexy musia byť zároveň odlišné od $i$. Mutantný vektor sa vytvorí vzťahom

$$\boldsymbol{v}_i^t = \boldsymbol{x}_{r_1}^t + F\big(\boldsymbol{x}_{r_2}^t - \boldsymbol{x}_{r_3}^t\big), \qquad 0 < F < 2.$$

Faktor $F$ určuje veľkosť zmeny vytvorenej z rozdielu dvoch náhodne vybraných vektorov. Vektor $\boldsymbol{x}_{r_1}^t$ predstavuje náhodne vybraný základ a rozdiel $\boldsymbol{x}_{r_2}^t - \boldsymbol{x}_{r_3}^t$ určuje smer zmeny. Násobenie faktorom $F$ upravuje jej veľkosť.

Skúšobný vektor vznikne binomickým krížením mutantného vektora s pôvodným jedincom. Pre každú zložku $j$ sa vygeneruje náhodné číslo $\rho_j$ z intervalu $(0, 1)$ a použije sa pravidlo

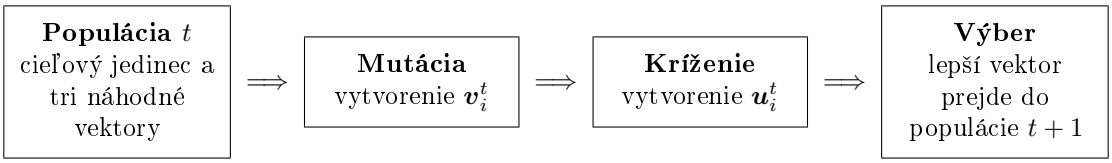
$$u_{i,j}^t = \begin{cases} v_{i,j}^t, & \text{ak } \rho_j < CR \text{ alebo } j = j_{\text{rand}}, \\ x_{i,j}^t, & \text{inak.} \end{cases}$$

Náhodne zvolený index $j_{\text{rand}}$ zabezpečuje, že aspoň jedna zložka skúšobného vektora pochádza z mutantného vektora. Bez tejto podmienky by pri malej hodnote $CR$ mohol skúšobný vektor zostať úplne zhodný s pôvodným jedincom.

Pri minimalizácii sa skúšobný vektor prijme, ak jeho fitness nie je horšia než fitness pôvodného jedinca:

$$\boldsymbol{x}_i^{t+1} = \begin{cases} \boldsymbol{u}_i^t, & \text{ak } f(\boldsymbol{u}_i^t) \le f(\boldsymbol{x}_i^t), \\ \boldsymbol{x}_i^t, & \text{inak.} \end{cases}$$

Výber je teda lokálny. Každý skúšobný jedinec súťaží priamo so svojím pôvodným jedincom. Najlepšia fitness populácie sa pri takomto výbere nemôže zhoršiť.




Obr. 1: Základný cyklus diferenciálnej evolúcie pre jedného cieľového jedinca.

Schéma na Obr. 1 sa vykoná pre každého jedinca populácie. Vektory použité pri tvorbe novej generácie sa musia vyberať z pôvodnej populácie danej generácie. Ak by sa priebežne používali už nahradené jedince, výsledok by závisel od poradia ich spracovania a išlo by o inú verziu algoritmu.

## Parametre, hranice a interpretácia výsledkov

Parameter $F$ ovplyvňuje veľkosť diferenciálneho kroku. Menšie hodnoty podporujú jemnejšie zmeny, ale môžu spomaliť prehľadávanie. Väčšie hodnoty podporujú rozsiahlejšie zmeny, no častejšie vytvoria riešenie mimo povoleného rozsahu. Parameter $CR$ určuje, koľko zložiek skúšobného vektora sa typicky prevezme z mutantného vektora. Vyššie $CR$ mení väčšiu časť riešenia, nižšie $CR$ zachováva viac z pôvodného jedinca.

Vhodná kombinácia $F$ a $CR$ závisí od optimalizovanej funkcie a nedá sa spoľahlivo určiť z jediného behu. Pri veľmi opatrnom nastavení môže populácia konvergovať pomaly alebo predčasne stratiť diverzitu. Pri príliš výrazných zmenách môže algoritmus dlhšie oscilovať medzi vzdialenými oblasťami a horšie dolaďovať nájdené riešenie. Preto sa parametre porovnávajú pri rovnakých podmienkach a výsledné nastavenie sa overuje vo viacerých behoch.

Ak mutantný alebo skúšobný vektor prekročí povolený rozsah premennej, treba použiť jednotný spôsob ošetrenia hraníc. Bežné možnosti sú orezanie na najbližšiu hranicu, odraz alebo nové náhodné určenie neplatnej zložky. Zvolený postup musí zostať rovnaký vo všetkých behoch, pretože môže ovplyvniť rýchlosť konvergencie aj kvalitu výsledku.

Graf najlepšej dovtedy dosiahnutej fitness ukazuje rýchlosť zlepšovania riešenia a okamih, keď sa ďalší pokrok zastavil. Päť samostatných priebehov ukazuje citlivosť algoritmu na náhodnú inicializáciu. Priemerný priebeh sumarizuje typické správanie, ale nenahrádza jednotlivé behy. Pri porovnaní s GA preto treba sledovať nielen najlepší výsledok, ale aj priemer, smerodajnú odchýlku a stabilitu konvergencie.